

# Clustering of dynamic graphs

Hauptseminar Networkvisualisation

Moritz Hamann



Abb. 1. In den Wolken: Vancouver von Cypress Mountain. Auf der ersten Seite dürfen keine Grafiken außer dieser optionalen Aufmachgrafik (Teaser) abgebildet sein.

**Kurzbeschreibung**—This paper presents a summary about various techniques to detect and identify densely connected nodes in a graph, so called clusters. In the first part, we introduce the concept of clusters for static graphs alongside their main properties. For dynamic graphs with time varying edge connections, these clusters may be subject to change with every time step. Therefore additional characteristics have to be introduced.

The second part describes two methods to detect, identify and track clusters in a dynamic graph. A common solution for this problem is the clustering of a static graph at each time step, and the identification of the same clusters over multiple time steps. A method is presented to track these clusters, which is independent of the underlying static graph clustering algorithm. Furthermore, we describe an extension of the k-clique percolation algorithm to dynamic graphs.

Finally, the clique percolation algorithm is applied to two different real world networks, which yields interesting results about group dynamics, with regards to the correlation of various group properties.

---

## 1 MOTIVATION

Das mathematische Konzept der Graphen ist ein essentielles Modellierungswerkzeug in der Informatik. Nicht nur lassen sich damit verschiedenste Datenstrukturen anschaulich darstellen, sondern mit ihrer Hilfe lassen sich auch jegliche Beziehungen zwischen einzelnen Objekten oder Prozessen in einem Netzwerk modellieren und untersuchen. Aus diesem Grund sind sie heutzutage nicht nur in der klassischen Informatik sowie in der Mathematik zu finden, sondern haben auch in vielen anderen Wissenschaften ihren Einzug erhalten. So werden sie genutzt um die Gruppendynamik in biologischen Netzwerken zu beschreiben, dienen als Kontrollalgorithmen für Multiagenten Systeme [?] und beschreiben Kommunikationsmuster in sozialen Netzwerken.

Um die Eigenschaften sehr großer Netzwerke analytisch untersuchen zu können, werden häufig Zufallsgraphen nach dem Model von Edgar Gilbert (nachweise?) oder Erdos-Renyi verwendet. Diese Graphen haben die Besonderheit, dass die Wahrscheinlichkeit für eine Verbindung zwischen je zwei Knoten im gesamten Netzwerk konstant ist. Dadurch entsteht ein gleichmäßiger Graph, dessen Gradverteilung binomial verteilt sind, und somit die meisten Knoten die gleiche Anzahl an Kanten haben. Mit Hilfe der Wahrscheinlichkeitstheorie, lassen sich nun die Eigenschaften dieser Graphen auch für eine sehr hohe Anzahl an Knoten bestimmen und untersuchen.

Allerdings haben Untersuchungen von realen Netzen gezeigt (nachweis), dass sich diese in den meisten Fällen von Zufallsgraphen unterscheiden. Reale Netzwerke sind häufig sogenannte Skalenfreie Netze (im Englischen 'Scale-free networks'), in denen die Anzahl der Verbindungen pro Knoten nicht binomial verteilt ist, sondern nach einem Potenzgesetz. Dadurch entsteht ein Netzwerk, in dem einzelne wenige Knoten eine große Anzahl an Verknüpfungen aufweisen, doch die Mehrzahl der Knoten weniger stark verknüpft ist. Weiterhin ist die Kantenverteilung zwischen den Knoten auch lokal sehr inhomogen, so dass sich Teilgraphen ausbilden, deren Knoten untereinander sehr stark bis komplett verknüpft sind, während sie nach Außen weniger Verbindungen aufweisen. Diese Teilgraphen werden auch 'Cluster' genannt.

Diese Cluster spielen in vielen Anwendungsgebieten eine wichtige Rolle. Betrachtet man zum Beispiel den Graph der Freundschaftsbeziehungen in einem sozialen Netzwerk, lassen sich mithilfe von Angaben anderer Benutzer, sowie lokaler Cluster, unter anderem Rückschlüsse auf gemeinsame Interessen, Wohnorte oder Freunde der einzelnen Benutzer schließen. Diese Informationen bieten dem sozialen Marketing eine bis vor kurzem unbekannte Menge an Möglichkeiten ihre Produkte zielgerichteter und persönlicher zu vermarkten. Aber auch in dynamischen Graphen, in denen Knoten und Kanten sehr häufig wechseln können, ist es wichtig Cluster zu finden. Betrachtet man den Verbindungsgraph eines dezentralen, kabellosen Ad-Hoc Netzwerks, so lassen sich mit Hilfe von Clustering Verfahren Teilnetze

finden die geographisch Eine zusätzliche Herausforderung zur eigentlichen Clusteranalyse ist hierbei allerdings

## Übersicht

Diese Arbeit gibt einen Überblick über die Eigenschaften dieser Cluster, ihr

## 2 GRUNDLAGEN

### 2.1 Formale Definition eines Clusters

In diesem Kaptiel wird versucht eine formale Definition zu geben, was ein Cluster in Graphen zu. Während die gewünschten Eigenschaften

#### 2.1.1 Eigenschaften von Clustern

Der Artikel von S.E. Schaeffer [11] bietet eine umfassende Zusammenfassung über bisherige Clustering Verfahren, und versucht eine Definition für Cluster anhand gewünschter Eigenschaften zu geben.

Betrachtet man den Teilgraphen  $\Omega$  eines kompletten Graphen  $\Upsilon$ , so müssen mehrere Bedingungen erfüllt sein, damit  $\Omega$  ein Cluster wird. Natürlich sollten alle Knoten aus  $\Omega$  verbunden sein, was bedeutet das zwischen jedem Paar aus Knoten  $u$  und  $v$  mit  $u, v \in \Omega$  ein Pfad existiert. Ist dies nicht der Fall so ist der gesamte Graph nicht verbunden, und das Clustering sollte auf den einzelnen Teilgraphen gesondert betrachtet werden. Weiterhin sollte der Teilgraph  $\Omega$  eine hohe Kantendichte zwischen seinen Knoten aufweisen. Dies ist der Fall, wenn mehrere Pfade zwischen den Knoten aus  $\Omega$  existieren, so dass jeder Pfad möglichst wenig Elemente aus  $\Upsilon \setminus \Omega$  enthält.

Der Grad  $d(v)$  eines Knoten  $v$  ist definiert als die Anzahl der Kanten zu anderen Knoten im Graphen  $\Upsilon$ . Ist nun  $v \in \Omega$  wobei  $\Omega$  wieder ein Teilgraph von  $\Upsilon$  ist, so lässt sich der Grad in einen externen und internen Teil unterscheiden. Dabei ist der interne Grad die Anzahl der Kanten von  $v$  zu anderen Knoten aus  $\Omega$ , der externe Grad die Anzahl der Kanten von  $v$  zu allen anderen Knoten aus  $\Upsilon \setminus \Omega$ . Dabei gilt:

$$d_{int}(v, \Omega) = |\Gamma(v) \cap \Omega| \quad (1)$$

$$d_{ext}(v, \Omega) = |\Gamma(v) \cap (\Upsilon \setminus \Omega)| \quad (2)$$

$$d(v) = d_{int}(v, \Omega) + d_{ext}(v, \Omega) \quad (3)$$

wobei  $\Gamma(v)$  die direkten Nachbarn von  $v$  sind. Eine Eigenschaft, die den Teilgraphen  $\Omega$  zu einem Cluster werden lässt, ist ein hohes Verhältniss von internem zu externem Grad für alle Knoten  $v \in \Omega$ , d.h. die Knoten eines Cluster haben untereinander wesentlich mehr Verknüpfungen als zu den Knoten des restlichen Graphen.

Eine weiteres Kriterium für die Qualität eines Clusters ist die sogenannte interne Clusterdichte. Die allgemeine Dichte eines Graphen  $\Upsilon = (V, E)$  mit der Knotenmenge  $V$  und der Kantenmenge  $E$  ist definiert als das Verhältniss der Summe aller Kanten durch die Anzahl aller möglichen Kanten in Graph:

$$\rho(\Upsilon) = \frac{|E|}{\binom{|V|}{2}} = \frac{2|E|}{|V|(|V| - 1)} \quad (4)$$

Somit lässt sich die interne Clusterdichte eines Clusters  $\Omega$  definieren als

$$\rho_{int}(\Omega) = \frac{|\{\{u, v\} | u, v \in \Omega\}|}{|\Omega|(|\Omega| - 1)} \quad (5)$$

wobei  $\{u, v\}$  eine Kante zwischen den Knoten  $u$  und  $v$  darstellt. Die fehlende 2 im Zähler im Vergleich zur allgemeinen Graphendichte ist dadurch zu erklären, dass  $\{u, v\}$  und  $\{v, u\}$  zwar die gleiche Kante darstellen, aber zwei unterschiedliche Elemente sind, wodurch die Anzahl der Kanten in  $\{\{u, v\} | u, v \in \Omega\}$  verdoppelt wird.

Zusätzlich zur internen Clusterdichte, existiert noch eine sogenannte externe Clusterdichte zwischen verschiedenen Clustern  $\Omega_i$  eines Graphen  $\Upsilon$ . Sie ist definiert als das Verhältniss der Summe aller Kanten

zu der Summe aller möglichen Kanten zwischen den verschiedenen Clustern  $\Omega_i$ :

$$\rho_{ext}(\Upsilon | \Omega_1 \dots \Omega_k) = \frac{|\{\{v, u\} | v \in \Omega_i, u \in \Omega_j, i \neq j\}|}{|V|(|V| - 1) - \sum_{i=1}^k |\Omega_i|(|\Omega_i| - 1)} \quad (6)$$

wobei  $|\Omega_i|$  die Anzahl der Knoten des Teilgraphen  $\Omega_i$  darstellt. Im Allgemeinen sollte für ein gutes Clustering auf einem Graph  $\Upsilon$  gelten:

$$\rho_{int}(\Omega_i) > \rho(\Upsilon) > \rho_{ext}(\Upsilon | \Omega_1 \dots \Omega_k) \quad (7)$$

$$\forall i = 1 \dots k$$

Abb. 2 zeigt drei verschiedene Cluster unterschiedlicher Qualität im Vergleich. Dabei representieren die schwarz hervorgehobenen, beliebig gewählten Teilgraphen jeweils einen Cluster. Der linke Cluster weist eine sehr hohe interne Dichte auf, und hat kaum Kanten mit Knoten ausserhalb. Daher ist Qualität dieses Clusters sehr hoch. Der mittlere Cluster hat zwar die gleiche Anzahl an internen Kanten, weist aber im Gegensatz zum Linken eine wesentliche höhere Kantenzahl zu Knoten ausserhalb des Cluster auf. Zwar hat der rechte Cluster nur wenige Kanten nach aussen, allerdings ist aber die Kantendichte innerhalb des Clusters minimalst, was ihn zum schlechtesten Cluster der drei macht.




Abb. 2. Drei verschiedene Cluster unterschiedlicher Qualität [11]

#### 2.1.2 k-Cliques

Einen Teilgraphen  $\Omega$  mit  $k$  Knoten nennt man  $k$ -Clique, falls alle  $k$  Knoten dieses Teilgraphen direkt miteinander verbunden sind, und  $\Omega$  somit vollständig ist [4]. Die entstehende Topologie des Teilgraphen  $\Omega$  ist natürlich vom Parameter  $k$  abhängig. Abb. 3 zeigt  $k$ -Cliques für verschiedene Werte von  $k$ .




Abb. 3. Topologien für  $k$ -Cliques mit  $k=2,3,4,5$

Da jede  $k$ -Clique vollständig ist, ist die in Kapitel 2.1.1 definierte interne Graphdichte mit  $\rho_{int}(\Omega) = 1$  maximal. Somit stellen  $k$ -Cliques theoretisch gute Kandidaten für Cluster da. Beschränkt man sich bei der Clusterfindung auf einzelne  $k$ -Cliques, werden in den meisten Fällen viele Cluster nicht gefunden, da Forderung an einen vollständig verknüpften Cluster zu restriktiv ist.

## 2.2 Dynamische Graphen

Ein klassischer Graph  $\Omega = (V, E)$  ist eine Kombination einer Menge an Knoten  $V$  und Kanten  $E$  zu einem bestimmten Zeitpunkt  $t$ . Für viele Anwendungen ist es aber essentiell das Netzwerk über einen Zeitraum mit mehreren Zeitschritten  $t_i$  zu betrachten und untersuchen.

Das Konzept der *dynamischen Graphen* [10] stellt die zeitliche Veränderung eines Graphen als geordnete Folge von statischen Teilgraphen für jeden Zeitpunkt  $t = 1, \dots, n$  da:

$$\Upsilon = \{\Omega_1 = (V_1, E_1), \Omega_2 = (V_2, E_2), \dots, \Omega_n = (V_n, E_n)\} \quad (8)$$

wobei  $\Omega_i$  der Konfiguration des dynamischen Graphen  $\Upsilon$  zum Zeitpunkt  $i$  entspricht. Da alle  $V_i, E_i$  für alle Werte von  $i$  unabhängig sind, ist es möglich das zu jedem Zeitschritt sowohl Kanten als auch Knoten hinzugefügt oder verschwinden können.

### 3 CLUSTERING IN STATISCHEN GRAPHEN

Viele Clustering Verfahren für dynamische Graphen basieren auf Verfahren zur Clustering klassischer, statischer Graphen. Da dynamische Graphen aufgrund der Zeitanhängigkeit weitere Komplexität einführen, ist es sinnvoll als erstes diese Clusteringmethoden für statische Graphen zu betrachten. In diesem Kapiel wird versucht die Vielzahl verschiedener Verfahren anhand ihrer grundsätzlichen Eigenschaften in verschiedene Kategorien zu klassifizieren, sowie eine kurze Erklärung ihrer Funktionsweise zu geben.

Nach Schaeffer [11] lassen sich Clustering Verfahren grundsätzlich in lokale oder globale Verfahren einteilen. Hierbei werden die Verfahren entweder global auf den ganzen Graph angewendet, oder nur lokal auf einen Teilgraphen. Entsprechend benötigen globale Verfahren Informationen über die Topologie des gesamten Graphen, während bei bei lokalen Verfahren nur rekursiv die Nachbarschaft eines einzelnen Knotens betrachtet wird, somit auch Netzwerke betrachtet werden können, die a priori nicht komplett bestimmt sind.

Entsprechend bieten lokale Verfahren eine bessere Skalierbarkeit als Globale, falls das Clustering nur auf einen Teilgraphen angewendet werden soll, da die Topologie des restlichen Graphen nicht bekannt sein muss. Weiterhin haben diese Verfahren den Vorteil, dass das Clustering nur von der lokalen Struktur abhängt und eine lokale Änderung im Graphen auch nur das Clustering in deren Umgebung beeinflusst. Deshalb eignen sich lokale Verfahren in Anwendungen, bei denen die Nachbarschaft einzelner Knoten schnell und häufig untersucht werden soll.

Tabelle 1. Einteilung der Clusteringverfahren für statische Graphen

	Globale Verfahren	Lokale Verfahren
Top-Down	Spektrale Methoden Random Walk Methoden Maximaler Fluss Methoden	
Bottom-Up	Modularitätsoptimierung Nächste Nachbarn Methode	CPM

#### Globale Verfahren

Die Familie der globalen Verfahren lässt sich noch mal in sogenannte *Top-Down*, sowie *Bottom-Up* Methoden [11] unterteilen. Bei Top-Down Verfahren wird der Graph rekursiv anhand verschiedener Kriterien in immer kleinere Methoden unterteilt, während bei Bottom-Up Verfahren viele kleinere Cluster sukzessive zu grösseren zusammen gefasst werden, bis das Clustering einem Abbruchkriterium genügt.

Ein Vertreter der Top-Down Methoden, sind die sogenannten *Spektralen Methoden*. Sie basieren auf den Eigenwerten und Vektoren der Laplace-Matrix des Graphen. Die Laplace Matrix eines Graph  $\Omega = (V, E)$  ist definiert als

$$L(\Omega) = D(\Omega) - A(\Omega) \quad (9)$$

wobei  $D(\Omega) = \text{diag}(\{d(v_1), \dots, d(v_n)\})$  die Degreematrix von  $\Omega$  ist [8].  $A(\Omega)$  ist die sogenannte Adjacency Matrix von  $\Omega$ , und definiert als

$$[A]_{ij} = \begin{cases} 1 & \text{falls zwischen } v_i \text{ und } v_j \text{ eine Kante besteht} \\ 0 & \text{sonst} \end{cases} \quad (10)$$

Da die Laplace Matrix eine symmetrische, positiv semidefinite Matrix ist [8], sind alle Eigenwerte  $\lambda_i \geq 0$  und die korrespondierenden Eigenvektoren bilden ein orthogonales System. Ordnet man die Eigenwerte in aufsteigender Reihenfolge  $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ , so folgt aus der positiv Semidefinitheit von  $L$  dass  $\lambda_1 = 0$ . Ist weiterhin  $\lambda_2 > 0$  so existieren keine isolierten Teilgraphen im kompletten Graph[Buch]. Die Algorithmen der spektralen Clustering Methoden benutzen typischerweise die Komponenten des Fiedler Vektors -den Eigenvektor von  $\lambda_2$ - um die Knoten des Graphen zu vergleichen und clustern [11].

Ein weitere Gruppe von Methoden die den Top-Down Ansatz verfolgen, sind die sogenannten *Random Walk* oder *Markov Ketten Methoden*. Diese Verfahren basieren auf einem zufälligen Weg  $\xi$  fester Länge durch den Graph. Dabei wird  $\xi$ , ausgehend von einem Startknoten  $v_{start}$ , iterativ über eine zufällige Auswahl der direkten Nachbarn des jeweils aktuellen Knoten aufgebaut. Aufgrund der höheren Dichte in Clustern, wird der Weg  $\xi$  die Knoten des selben Clusters wie  $v_{start}$  häufiger besuchen als Knoten ausserhalb des Clusters. Abb. 4 zeigt einen Beispielgraph mit zwei Clustern. Wird ein Weg ausgehend von einem weissen Knoten aufgebaut, ist es für einen zufälligen Weg nur auf einem Knoten möglich den linken Cluster zu verlassen, und somit werden die weissen Knoten des linken Clusters mit einer höheren Wahrscheinlichkeit besucht.




Abb. 4. [11]

Für gewichtete Graphen eignen sich auch die *Maximaler Fluss Methoden* um ein Clustering durchzuführen. Sie gehören ebenfalls zu der Gruppe der Top-Down Verfahren, und versuchen einen minimalen Schnitt [11] des Graphen zu finden. Dazu werden Strömungsberechnungen auf dem Graphen durchgeführt, wobei ein Fluss zwischen zwei Knoten nur über eine Verbindungskante bestehen kann. Da aufgrund des *Minimum cut, maximum Flow Theorems* der Schnitt eines Graphen beim maximalen Fluss am geringsten ist, lässt sich dieser über den maximalen Fluss auf den Kanten des Graphen finden. Flake et al.[5] berechneten hierzu den Fluss mithilfe künstlich hinzugefügter Senken, und erzeugten daraus einen Minimum-cut Tree[6] um das Clustering auf einem Graphen durchzuführen.

Beispiele für Methoden, die einen Bottom-Up Ansatz verwenden sind unter anderem die *Modularitätsoptimierung* welche in Kapiel 3.1 genauer behandelt wird. Eine weitere Vertreter ist die sogenannte *Nächste Nachbarn Methode*[11], welche häufig auch bei allgemeinen Klassifizierungsproblemen angewendet wird. Um die Nächste Nachbarn Methode auf Graphen anwenden zu können, muss eine Ähnlichkeit zwischen zwei Knoten definiert werden. Eine solche Ähnlichkeit kann z.B. anhand von vorhandenen Metadaten jedes Knoten erfolgen, oder anhand der Schnittmenge der direkten Nachbarn zweier Knoten. Im ersten Schritt wird für jeden Knoten des Graphen derjenige Nachbar gesucht, für welchen die Ähnlichkeit am grössten ist. Diese beiden Knoten bilden nun einen Cluster. In den darauffolgenden Schritten, werden nun die bereits gefunden Cluster auf Ähnlichkeit untersucht, und zu grösseren Cluster zusammengefügt, bis das Clustering beendet ist.

#### 3.1 Modularitätsoptimierung

Das Verfahren der Modularitätsoptimierung ist ein weiterer Vertreter der Bottom-Up Ansätze. Es versucht eine Partitionierung des Graphen zu finden, für die die Modularität maximal wird. Hierbei ist die Modularität ein Maß, in wie fern die gewählte Partitionierung  $C(\Omega)$  eines Graphen  $\Omega$  einem guten Clustering entspricht. Gesucht ist somit eine optimale Partitionierung welche dem Clustering des Graphen entspricht. Mathematisch ist die Modularität  $Q(C)$  definiert als [10]:

$$Q(C) = \frac{1}{2|E|} \sum_{u,v \in V} \left[ A_{uv} - \frac{k_u k_v}{2|E|} \delta(c(u), c(v)) \right] \quad (11)$$

wobei  $A_{uv} = 1$  falls eine Kante zwischen  $u$  und  $v$  existiert, ansonsten 0.  $k_u = d(u)$  ist der Grad des Knoten, und  $c(u)$  diejenige Partition die den Knoten  $u$  enthält. Weiterhin ist  $\delta(c(u), c(v))$  falls  $c(u) = c(v)$ ,

ansonsten 0. Somit repräsentiert die Modularität die Summe aller Kanten innerhalb einer Partition minus der Anzahl der Kanten, falls diese zufällig verteilt wären.

Der trivialste Ansatz diejenige Partitionierung  $C(\Omega)$  zu finden welche die Modularität maximiert, wäre die Berechnung aller möglichen Partitionen und ihrer dazugehörigen Modularität. Es ist aber offensichtlich, dass bei steigender Graphgröße die Anzahl möglicher Partitionen rasant steigt. Weiterhin wurde gezeigt [2], dass das Problem eine optimale Partition zu finden NP-Vollständig ist.

Eine optimale Partitionierung, und somit ein Clustering kann mithilfe der Heuristik von Blondel et al. [1] approximiert werden. Der wesentliche Bestandteil der Heuristik ist die Tatsache, dass die Änderung der Modularität  $\Delta Q$ , falls ein Knoten  $v_i$  in den Cluster  $C$  verschoben wird, lokal effizient berechnet werden kann:

$$\Delta Q = \left[ \frac{\sum_{in} + k_{i,in}}{2m} - \left( \frac{\sum_{tot} + k_i}{2m} \right)^2 \right] - \left[ \frac{\sum_{in}}{2m} - \left( \frac{\sum_{tot}}{2m} \right)^2 - \left( \frac{k_i}{2m} \right)^2 \right] \quad (12)$$

wobei  $\sum_{in}$  die Summe der Gewichte aller Kanten des Clusters  $C$  ist,  $\sum_{tot}$  die Summe der Gewichte aller Kanten welche mit Knoten des Cluster  $C$  verbunden sind,  $k_i$  ist die Summe der Gewichte aller Kanten des Knoten  $v_i$ ,  $k_{i,in}$  ist die Summe der Gewichte aller Kanten welche den Knoten  $i$  mit Knoten aus  $C$  verbinden, und  $m$  die Anzahl aller Kanten im Graph. Hierbei bleibt zu erwähnen, das sogenannte *Selfloops*, also Kanten von  $v_i$  nach  $v_i$  erlaubt sind, und sogar ein wesentlicher Teil der Heuristik darstellen.

Die Heuristik läuft nun wie folgt ab:

1. Für jeden Knoten wird ein einzelner Cluster erstellt, der nur diesen einen Knoten enthält
2. Berechnung der  $\Delta Q$  für das Verschieben eines Knoten  $v_i$  in die Cluster seiner direkten Nachbarn. Anschließend wird  $v_i$  in den Cluster desjenigen Nachbarn  $v_j$  verschoben, dessen  $\Delta Q$  am grössten ist. Ist die Zunahme der Modularität für jeden Nachbarn negativ, so bleibt der Knoten  $v_i$  in seinem Cluster. Dieser Schritt wird solange wiederholt, bis sich ein lokales Maxima der Modularität einstellt. Dabei ist es durchaus möglich das ein Knoten mehrmals betrachtet wird.
3. Ist ein lokales Maxima erreicht, wird einer neuer Graph aufgebaut. Dabei entsprechen die bisherigen Cluster den Knoten des neuen Graph. Diese sind verbunden falls mindestens eine Kante zwischen je einem Knoten der beiden Cluster existiert und das Gewicht dieser Kante ist die Summe der Gewichte aller Kanten zwischen diesen Clustern. Kanten innerhalb eines Cluster führen zu einem Selfloop dessen Gewicht die Summe der Gewichte dieser Kanten ist.
4. Führe Schritte 1-3 wiederum auf den neuen Graph aus, solange bis die Modularität nicht weiter erhöht werden kann.

### 3.2 Clique Percolation Method (CPM)

Alle bisher vorgestellten Methoden waren globale Clusteringverfahren. Ein lokales Verfahren ist die *Clique Percolation Method (CPM)*[4], welche auf den in Kap. 2.1.2 vorgestellten  $k$ -Cliques beruht. Hierzu wird eine Nachbarschaftsbeziehung zwischen  $k$ -Cliques definiert, bei der zwei  $k$ -Cliques benachbart sind, falls diese sich  $k-1$  Knoten teilen.

Ein Cluster in der CPM ist definiert als eine maximale Menge von  $k$ -Cliques, welche über eine Nachbarschaft erreichbar sind. Dabei wird die CPM jeweils für ein festgelegtes  $k$  durchgeführt. Es existieren verschiedene Algorithmen mithilfe derer eine CPM durchgeführt werden kann, z.B. der Bron-Kerbosch Algorithmus.

Abb. 5 zeigt die gefundenen 3-Cliques Cluster einer CPM für einen willkürlichen Graphen. Im linken sowie rechten Graph werden jeweils zwei Cluster gefunden, welche durch graue und schwarze Einfärbung hervorgehoben sind. Im rechten Graph ist zu erkennen, dass sich

Cluster, welche mithilfe einer CPM gefunden wurden, ein oder mehrere Knoten teilen können. Somit ist es auch möglich überlappende Cluster in einem Netzwerk zu finden, welche vor allem in sozialen Netzwerken auftreten.




Abb. 5. aus paper

## 4 CLUSTERING IN DYNAMISCHEN GRAPHEN

Bei einem Clustering eines dynamischen Graphens, ist neben der Identifikation der Cluster ansich, auch deren zeitlichen Verlauf von Interesse. Hierzu können die bisher vorgestellten Clusteringverfahren für statische Graphen erweitert oder modifiziert werden, damit die gefundenen Cluster über die Zeitschritte verfolgt werden können.

Hierzu lassen sich die Verfahren in zwei Klassen einteilen. *Evolutionäre Clustering Verfahren*[3] verwenden Graphinformationen mehrerer konsekutiver Zeitschritte um ein Clustering durchzuführen. Zum Beispiel verwendet die Erweiterung der CPM in Kap. 4.2 Graphinformationen des aktuellen, sowie des nächsten Zeitschritt. Ziel der evolutionären Clusteringverfahren ist es ein über mehrere Zeitschritte konsistentes Clustering zu finden, in welchem weiche Übergänge zwischen Clustern der einzelnen Zeitschritten besteht.

Die andere Klasse der Clusteringverfahren dynamischer Graphen wird hier *Time-step Clustering* genannt. Im Gegensatz zu den evolutionären Clusteringverfahren, verwenden sie nur den statischen Graph des aktuellen Zeitschritt um ein Clustering zu finden. Dies hat den Vorteil das Clusteringverfahren statischer Graphen, somit auch die in Kap. 3 vorgestellten Verfahren, ohne Modifikation verwendet werden können. Da nur die Informationen des aktuellen Zeitschritt verwendet werden, dass sich die gefunden Cluster in konsekutiven Zeitschritten sehr stark ändern.

Für Verfahren beider Klassen ist es notwendig gefundene Cluster verschiedener Zeitschritte zu vergleichen, um spezifische Cluster über mehrerer Zeitschritte zu verfolgen. Dazu wird der *Jaccard-Koeffizient* verwendet, mithilfe dessen zwei Mengen auf Ähnlichkeit untersucht werden können. Für die Mengen  $A$  und  $B$  ist er definiert als [7]:

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|} \quad (13)$$

wobei  $|A|$  die Anzahl der Elemente in  $A$  ist. Somit ist der Wertebereich des Jaccard-Koeffizient  $[0, 1]$  mit 1 als maximaler Übereinstimmung.

### 4.1 Evolution eins Clusters

Betrachtet man den zeitlichen Verlauf eines Clusters, so können verschiedene Ereignisse auftreten. Zu jedem Zeitpunkt kann ein neuer Cluster entstehen, ebenso kann sich ein bestehender Cluster auflösen. Weiterhin können neue Cluster entstehen, falls sich bisherige grosse Cluster teilen. Ebenso ist das Gegenteil möglich, und mehrere kleinere Cluster formieren sich im nächsten Zeitschritt zu einem Grossen. Im einfachsten Fall bleibt ein Cluster im nächsten Zeitschritt konstant, wächst oder schrumpft indem neue Knoten hinzukommen oder weggehen. In Abb. 6 sind alle möglichen Ereignisse noch einmal dargestellt.

### 4.2 Erweiterung der CPM

Palla et al. haben in [9] die in Kaptiel 3.2 vorgestellte Clique Percolation Method erweitert, um sie auf dynamische Graphen anzuwenden. Dabei wird ein evolutionärer Ansatz verwendet, welcher den Graphen zum Zeitpunkt  $t$ , als auch zum Zeitpunkt  $t+1$  benutzt.

Im ersten Schritt wird mithilfe der CPM für statische Graphen jeweils ein Clustering für die Zeitschritte  $t$  und  $t+1$  durchgeführt. Anschließend wird ein mithilfe der Vereinigung der Graphen

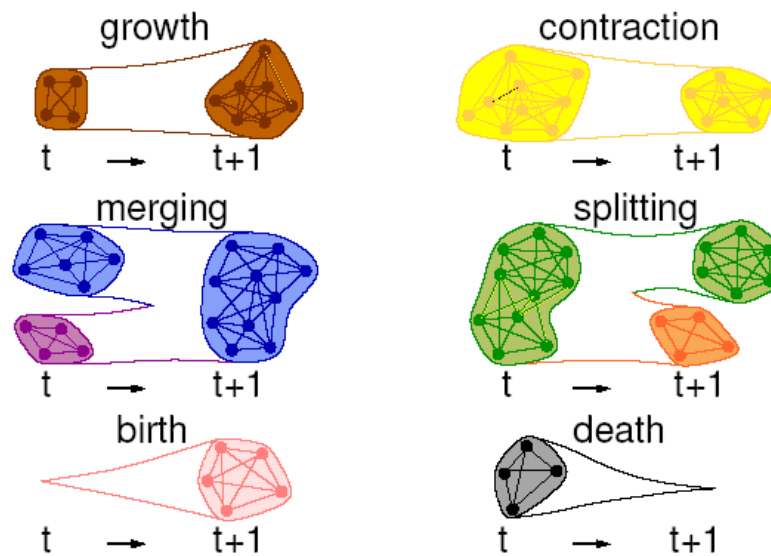


Abb. 6. [9]

### 4.3 Time step Clustering

## 5 CONCLUSION

### LITERATUR

- [1] V. D. Blondel, J.-L. Guillaume, R. Lambiotte, and E. Lefebvre. Fast unfolding of communities in large networks. Juli 2008.
- [2] U. Brandes, D. Delling, M. Gaertler, R. Görke, M. Hoefer, Z. Nikoloski, and D. Wagner. Maximizing modularity is hard. August 2006.
- [3] D. Chakrabarti, R. Kumar, and A. Tomkins. Evolutionary clustering. 2006.
- [4] I. Derényi, G. Palla, and T. Vicsek. Clique percolation in random networks. April 2005.
- [5] G. W. Flake, R. E. Tarjan, and K. Tsioutsoulis. Graph clustering and minimum cut trees. April 2004.
- [6] R. Gomery and T. Hu. Multi-terminal network flows. *SIAM Journal* 9, 1961.
- [7] D. Greene, D. Doyle, and P. Cunningham. Tracking the evolution of communities in dynamic social networks. August 2010.
- [8] M. Mesbahi and M. Egerstedt. *Graph Theoretic Methods in Multiagent Networks*. Princeton University Press, first edition, 2010.
- [9] G. Palla, A.-L. Barabási, and T. Vicsek. Quantifying social group evolution.
- [10] A. Sallaberry, C. Muelder, and K.-L. Ma. Clustering, visualizing, and navigating for large dynamic graphs. September 2012.
- [11] S. E. Schaeffer. Graph clustering. May 2007.